

# UJIAN TENGAH SEMESTER

Pembelajaran Mesin — Genap 2025/2026

**Prediksi Risiko Burnout dan Kebutuhan Dukungan  
Kesehatan Mental pada Karyawan  
Menggunakan Perbandingan Algoritma Random Forest dan SVM**



|                    |                           |
|--------------------|---------------------------|
| <b>Nama</b>        | Nashwa Harvani Rubiantono |
| <b>NIM</b>         | A11.2024.15544            |
| <b>Kelompok</b>    | 4404                      |
| <b>Mata Kuliah</b> | Pembelajaran Mesin        |

## SOAL 1: PROBLEM FORMULATION & LEARNING TASK (Bobot: 20%)

---

### 1.1 Latar Belakang Masalah

Pasca pandemi COVID-19, model kerja hibrida (*Work From Home* dan *Work From Office*) telah bertransformasi menjadi standar baru di berbagai sektor industri global. Transisi pola kerja ini membawa dampak signifikan terhadap stabilitas kesehatan mental karyawan, terutama terkait fenomena **burnout**—sebuah kondisi kelelahan kronis yang dipicu oleh tekanan kerja berlebih secara berkepanjangan. Berdasarkan data survei global, prevalensi gejala *burnout* telah mencapai angka kritis, di mana lebih dari 40% karyawan melaporkan penurunan kesejahteraan mental sejak tahun 2022.

Namun, pada realitasnya, perusahaan sering kali baru menyadari kondisi *burnout* tersebut ketika produktivitas telah menurun drastis atau saat karyawan memutuskan untuk mengundurkan diri (*resign*). Kondisi ini mengindikasikan adanya celah besar dalam mekanisme **deteksi dini** yang efektif di lingkungan kerja. Saat ini, manajemen SDM sangat membutuhkan instrumen analitis yang mampu mengidentifikasi karyawan berisiko tinggi secara proaktif, sehingga intervensi yang tepat sasaran dapat segera dilakukan sebelum dampak buruk terjadi secara permanen.

### 1.2 Mengapa Machine Learning Diperlukan?

Pendekatan berbasis aturan (rule-based) tidak memadai untuk mendeteksi burnout karena:

- Faktor pemicu burnout bersifat multidimensi dan non-linear — kombinasi jam kerja, pola komunikasi, akses fasilitas, dan kondisi pribadi berinteraksi secara kompleks.
- Rule-based memerlukan threshold yang kaku dan tidak dapat menyesuaikan diri dengan variasi antar individu maupun perubahan konteks industri.
- Machine Learning mampu menemukan pola tersembunyi dari data historis dan menghasilkan prediksi probabilistik yang lebih akurat untuk klasifikasi risiko burnout.
- ML dapat memperbarui modelnya seiring data baru tersedia, sehingga adaptif terhadap perubahan dinamika kerja.

### 1.3 Definisi Learning Task

Jenis Learning Task: Supervised Learning — Klasifikasi Multi-Kelas

| Komponen              | Deskripsi                                                                                                                                                                                               |
|-----------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Target/Label Variable | Burnout_Level — kategori: Rendah, Sedang, Tinggi<br><b>Rendah:</b> Kondisi ideal, produktivitas stabil.<br><b>Sedang:</b> Indikasi awal kelelahan, memerlukan pemantauan atau <i>wellness program</i> . |

|                  |                                                                                                                                               |
|------------------|-----------------------------------------------------------------------------------------------------------------------------------------------|
|                  | <b>Tinggi:</b> Risiko kritis, memerlukan intervensi langsung dari manajer atau profesional kesehatan.                                         |
| Input Features   | Work_Hours_Per_Week, Remote_Work_Status, Access_to_Mental_Health_Resources, Years_of_Experience, Job_Role, Overtime_Hours, Stress_Level, dll. |
| Tipe Data Target | Kategorikal (3 kelas)                                                                                                                         |

## 1.4 Hipotesis Awal

**H1:** Model **Random Forest** diproyeksikan akan mencapai tingkat akurasi yang lebih unggul dibandingkan dengan model **Support Vector Machine (SVM)** melalui kemampuannya dalam menangani hubungan non-linear yang kompleks antar fitur serta ketahanannya terhadap data pencilan (*outlier*) pada dataset survei berskala menengah (3.000+ sampel).

**H2:** Variabel **Work\_Hours\_Per\_Week** dan **Overtime\_Hours** diprediksi akan menjadi prediktor paling signifikan terhadap klasifikasi tingkat *burnout* karyawan, sebagaimana dibuktikan melalui analisis bobot kepentingan fitur (*feature importance*) yang dihasilkan oleh algoritma Random Forest.

## SOAL 2: DATASET & REPRESENTASI DATA (Bobot: 20%)

### 2.1 Sumber Dataset

| Atribut              | Detail                                                                                                     |
|----------------------|------------------------------------------------------------------------------------------------------------|
| Sumber               | Kaggle ( <a href="#">Employee Mental Health &amp; Burnout 2026</a> )                                       |
| Metode               | Pengumpulan data sekunder dari dataset publik terverifikasi                                                |
| Data yang dianalisis | Jam kerja, status kerja remote, akses kesehatan mental, pengalaman kerja, level stres, dan tingkat burnout |
| Jumlah Sampel        | ± 3.000 data karyawan dari berbagai sektor industri                                                        |
| Karakteristik        | Data tabular multidimensi (Campuran numerik dan kategorikal)                                               |
| Status               | Public dataset — Updated 2026 (Untuk keperluan penelitian)                                                 |

### 2.2 Struktur Data

- Tipe Struktur: Tabular (CSV)
- Jumlah Fitur: ±12–15 fitur (numerik dan kategorikal)
- Target Variable: 1 kolom (Burnout\_Level)

### 2.3 Tabel Deskripsi Fitur

| Nama Fitur          | Tipe Data     | Peran | Deskripsi                      |
|---------------------|---------------|-------|--------------------------------|
| Work_Hours_Per_Week | Numerik (INT) | Input | Rata-rata jam kerja per minggu |

|                         |                                   |        |                                                   |
|-------------------------|-----------------------------------|--------|---------------------------------------------------|
| Overtime_Hours          | Numerik (INT)                     | Input  | Jam lembur rata-rata per minggu                   |
| Remote_Work_Status      | Kategorikal (Categorical)         | Input  | Status WFH / WFO / Hybrid                         |
| Access_to_Mental_Health | Kategorikal (Categorical)         | Input  | Ketersediaan fasilitas kesehatan mental di kantor |
| Stress_Level            | Ordinal (INT 1-10)                | Input  | Tingkat stres subjektif (skala 1–10)              |
| Years_of_Experience     | Numerik (Float)                   | Input  | Lama pengalaman kerja karyawan (tahun)            |
| Job_Role                | Kategorikal (String)              | Input  | Peran/jabatan karyawan                            |
| Industry_Sector         | Kategorikal (String)              | Input  | Sektor industri tempat bekerja                    |
| Sleep_Quality           | Ordinal (INT 1-5)                 | Input  | Kualitas tidur (skala 1–5)                        |
| Physical_Activity       | Kategorikal (Categorical)         | Input  | Frekuensi aktivitas fisik mingguan                |
| Burnout_Level           | Kategorikal (Categorical 3 Kelas) | TARGET | Rendah / Sedang / Tinggi                          |

## 2.4 Analisis Representasi Data

Feature vs Target: Seluruh fitur input akan dianalisis korelasinya dengan target Burnout\_Level. Fitur numerik menggunakan korelasi Spearman, sedangkan fitur kategorikal menggunakan uji Chi-Square.

Potensi Bias Data: Dataset mungkin over-representasi pada sektor teknologi atau karyawan kantoran, sehingga perlu validasi distribusi data berdasarkan Job\_Role dan Industry\_Sector sebelum pemodelan.

Potensi Imbalance: Kelas 'Tinggi' kemungkinan lebih sedikit dari kelas 'Rendah' karena sifat survei. Akan ditangani dengan teknik oversampling SMOTE jika rasio antar kelas melebihi 1:3.

## 2.5 Tantangan Dataset

| Tantangan           | Deskripsi                                                                                                           | Solusi Yang Direncanakan                                                                                                         |
|---------------------|---------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------|
| Missing Values      | Data survei seringkali memiliki atribut atau pertanyaan yang tidak diisi oleh responden.                            | Melakukan teknik <b>Imputasi</b> ; menggunakan <i>mean</i> untuk fitur numerik dan <i>modus</i> untuk fitur kategorikal.         |
| Noise               | Adanya respons subjektif ekstrem pada fitur skala (seperti stres atau tidur) yang berpotensi menjadi data pencilan. | Deteksi <i>outlier</i> menggunakan metode <b>Box Plot</b> dan <b>Interquartile Range (IQR)</b> untuk memastikan integritas data. |
| High Dimensionality | Jumlah fitur yang cukup banyak (12–15 fitur) dapat meningkatkan kompleksitas model.                                 | Seleksi fitur berbasis <b>Random Forest Feature Importance</b> atau reduksi                                                      |

|                    |                                                                                                    |                                                                                                                             |
|--------------------|----------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------|
|                    |                                                                                                    | dimensi menggunakan <b>PCA</b> jika diperlukan.                                                                             |
| Label Subjectivity | Penentuan Burnout_Level seringkali bersifat subjektif, menyebabkan batas antar kelas menjadi bias. | Verifikasi distribusi label dan analisis korelasi antar fitur untuk memvalidasi konsistensi pengelompokan tingkat risiko.   |
| Class Imbalance    | Kemungkinan dominasi data pada salah satu kelas (misal: kelas Rendah >> Tinggi).                   | Implementasi <b>SMOTE</b> ( <i>Synthetic Minority Over-sampling Technique</i> ) untuk menyeimbangkan proporsi kelas target. |

## SOAL 3: MACHINE LEARNING PIPELINE DESIGN (Bobot: 20%)

### 3.1 Data Preprocessing

#### A. Data Cleaning

- Deteksi dan penanganan missing values: imputasi mean untuk fitur numerik (Work\_Hours\_Per\_Week, Overtime\_Hours), imputasi modus untuk fitur kategorikal (Remote\_Work\_Status, Job\_Role).
- Deteksi outlier menggunakan metode IQR pada fitur numerik dan penanganan dengan Winsorization (mengganti nilai ekstrem dengan persentil 5 dan 95).
- Penghapusan duplikat data survei.

#### B. Encoding

- One-Hot Encoding untuk fitur nominal tanpa urutan: Remote\_Work\_Status (WFH/WFO/Hybrid), Job\_Role, Industry\_Sector, Physical\_Activity.
- Ordinal Encoding untuk fitur ordinal: Stress\_Level (1–10), Sleep\_Quality (1–5).
- Label Encoding untuk target: Burnout\_Level (Rendah=0, Sedang=1, Tinggi=2).

#### C. Scaling

- StandardScaler wajib diterapkan pada semua fitur numerik untuk algoritma SVM agar jarak antar data seimbang (SVM sensitif terhadap skala fitur).
- Random Forest tidak memerlukan scaling, namun tetap diterapkan agar pipeline konsisten.

### 3.2 Feature Engineering

- Pembuatan fitur baru Overtime\_Ratio = Overtime\_Hours / Work\_Hours\_Per\_Week sebagai indikator proporsional tekanan kerja.
- Binning Work\_Hours\_Per\_Week menjadi kategori (Normal: <40 jam, Sedang: 40–50 jam, Tinggi: >50 jam) untuk analisis eksplorasi.

### 3.3 Data Splitting Strategy

Strategi yang digunakan adalah Stratified Train-Validation-Test Split dengan proporsi 70:15:15 untuk memastikan distribusi kelas seimbang di setiap subset.

| Subset | Proporsi | Fungsi |
|--------|----------|--------|
|--------|----------|--------|

|                |                   |                                                |
|----------------|-------------------|------------------------------------------------|
| Training Set   | 70% (~2.100 data) | Melatih model                                  |
| Validation Set | 15% (~450 data)   | Tuning hyperparameter                          |
| Test Set       | 15% (~450 data)   | Evaluasi akhir model yang tidak pernah dilihat |

Untuk optimasi tambahan, digunakan juga 5-Fold Stratified Cross Validation pada training set untuk mengestimasi performa model secara lebih stabil.

### 3.4 Pipeline Workflow (End-to-End)

| Tahap          | Proses                                                                                     | Tools/Library                 |
|----------------|--------------------------------------------------------------------------------------------|-------------------------------|
| Input Data     | Data Loading dari format Raw CSV (Kaggle dataset)                                          | Pandas, Python                |
| EDA            | Analisis distribusi fitur, korelasi antar variabel, dan visualisasi <i>outlier</i>         | Matplotlib, Seaborn           |
| Data Cleaning  | Penanganan <i>Missing Values</i> (imputasi) dan eliminasi <i>outlier</i> via IQR           | Pandas, Scikit-learn          |
| Preprocessing  | <i>Feature Engineering</i> , <i>Encoding</i> (One-Hot/Ordinal), dan <i>Feature Scaling</i> | Scikit-learn (StandardScaler) |
| Data Split     | Pembagian data menjadi Train, Validation, dan Test set                                     | Scikit-learn                  |
| Model Training | Implementasi algoritma Random Forest dan SVM                                               | Scikit-learn                  |
| Optimization   | <i>Hyperparameter Tuning</i> menggunakan metode <i>Grid Search</i>                         | Scikit-learn                  |
| Evaluation     | Pengukuran performa via <i>Confusion Matrix</i> , F1-Score, dan ROC-AUC                    | Scikit-learn, Matplotlib      |
| Model Saving   | <i>Serialization</i> model terbaik untuk keperluan penggunaan kembali                      | Pickle, Joblib                |
| Deployment     | Pengembangan antarmuka aplikasi deteksi dini <i>burnout</i>                                | Streamlit                     |

## SOAL 4: MODELING STRATEGY & EXPERIMENT DESIGN (Bobot: 20%)

### 4.1 Algoritma yang Dipilih

#### A. Random Forest (RF)

- Cara Kerja: Random Forest adalah algoritma ensemble yang membangun sejumlah besar pohon keputusan (decision tree) secara paralel menggunakan teknik bagging (Bootstrap Aggregating). Setiap pohon dilatih pada subset data yang diambil secara acak dengan penggantian (bootstrap sample), dan pada setiap node, hanya sebagian fitur yang dipilih secara acak untuk splitting. Hasil prediksi akhir ditentukan berdasarkan voting mayoritas dari seluruh pohon.

- Alasan Pemilihan: Efektif menangani data non-linear dan fitur yang beragam tipe (numerik dan kategorikal); tahan terhadap overfitting; memberikan feature importance secara langsung; tidak sensitif terhadap outlier; performa stabil pada dataset berskala menengah.

## B. Support Vector Machine (SVM)

- Cara Kerja: SVM bekerja dengan mencari hyperplane optimal yang memaksimalkan margin antara kelas dalam ruang fitur berdimensi tinggi. Untuk masalah non-linear, SVM menggunakan kernel trick (RBF/Gaussian) untuk memetakan data ke dimensi lebih tinggi di mana pemisahan linear menjadi mungkin. Pada klasifikasi multi-kelas, digunakan strategi One-vs-Rest (OvR).
- Alasan Pemilihan: Efektif pada ruang fitur berdimensi tinggi setelah one-hot encoding; bekerja baik pada dataset berukuran menengah; memberikan solusi yang robust dengan margin maksimum; sebagai algoritma pembanding yang berbasis pendekatan geometri (berbeda dari RF yang berbasis ensemble trees).

## 4.2 Rancangan Eksperimen

Hyperparameter Tuning menggunakan Grid Search dengan 5-Fold Cross Validation:

| Algoritma     | Hyperparameter    | Nilai yang Diuji         |
|---------------|-------------------|--------------------------|
| Random Forest | n_estimators      | 100, 200, 300            |
|               | max_depth         | None, 10, 20, 30         |
|               | min_samples_split | 2, 5, 10                 |
|               | class_weight      | None, balanced           |
| SVM           | C (regularisasi)  | 0.1, 1, 10, 100          |
|               | kernel            | rbf, poly, linear        |
|               | gamma             | scale, auto, 0.001, 0.01 |
|               | class_weight      | None, balanced           |

## 4.3 Metrik Evaluasi

| Metrik            | Deskripsi Teknis                                                                                | Relevansi dalam Kasus <i>Burnout</i>                                                                                               |
|-------------------|-------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------|
| Accuracy          | Rasio total prediksi benar terhadap keseluruhan data sampel.                                    | Digunakan sebagai gambaran umum performa model secara global.                                                                      |
| Precision (Macro) | Rasio prediksi benar positif dibandingkan dengan total hasil yang diprediksi positif.           | Penting untuk meminimalkan <i>false positive</i> pada label risiko "Tinggi" agar intervensi tepat sasaran.                         |
| Recall (Macro)    | Kemampuan model mengidentifikasi seluruh sampel yang benar-benar masuk dalam kategori tertentu. | <b>Kritis;</b> mengantisipasi <i>missed detection</i> pada kelas risiko tinggi yang dapat berakibat fatal bagi kesehatan karyawan. |

|                  |                                                                                             |                                                                                                                                |
|------------------|---------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------|
| F1-Score (Macro) | Nilai rata-rata harmonik antara <i>Precision</i> dan <i>Recall</i> .                        | <b>Metrik Utama</b> ; memberikan penilaian seimbang jika terjadi ketidakseimbangan distribusi data ( <i>class imbalance</i> ). |
| ROC-AUC (OvR)    | <i>Area Under Curve</i> dengan pendekatan <i>One-vs-Rest</i> untuk klasifikasi multi-kelas. | Mengukur kemampuan diskriminasi model dalam membedakan tingkatan risiko secara keseluruhan.                                    |
| Confusion Matrix | Tabel kontingensi yang memetakan label aktual terhadap hasil prediksi model.                | Visualisasi utama untuk mengidentifikasi distribusi <i>error</i> dan pergeseran klasifikasi antar kelas.                       |

#### 4.4 Rencana Analisis Overfitting vs Underfitting

- Overfitting diindikasikan jika Training Accuracy >> Validation Accuracy (gap > 10%). Penanganan: menambah regularisasi (RF: max\_depth lebih kecil; SVM: nilai C lebih kecil), atau menambah data.
- Underfitting diindikasikan jika baik Training maupun Validation Accuracy rendah (<70%). Penanganan: menambah kompleksitas model (lebih banyak estimator/tree depth) atau menambah fitur.
- Bias-Variance Tradeoff: Random Forest mengurangi variance melalui averaging, namun bisa memiliki bias tinggi jika max\_depth terlalu kecil. SVM dengan kernel RBF dapat berisiko overfitting jika C terlalu besar — dikontrol dengan Cross Validation.
- Learning Curve akan dibuat untuk memantau perubahan training/validation score seiring penambahan data.

### SOAL 5: MODEL DEPLOYMENT PLAN (Bobot: 20%)

#### 5.1 Bentuk Deployment

Aplikasi web interaktif menggunakan Streamlit — dipilih karena mudah digunakan oleh tim SDM non-teknis, tidak memerlukan konfigurasi server yang kompleks, dan dapat dideploy dengan cepat melalui Streamlit Cloud.

#### 5.2 Alur Input → Model → Output

| Tahap         | Komponen                           | Detail                                                                                           |
|---------------|------------------------------------|--------------------------------------------------------------------------------------------------|
| Input         | User Interface (Streamlit Web App) | Pengguna memasukkan data parameter kerja dan psikologis melalui form web atau unggahan file CSV. |
| Preprocessing | Data Processor Module              | Validasi data, penanganan <i>missing values</i> (imputasi), dan normalisasi rentang nilai fitur. |
| Encoding      | Feature Transformer                | Konversi variabel kategorikal menjadi numerik (One-                                              |



|                 |                             |                                                                                                                      |
|-----------------|-----------------------------|----------------------------------------------------------------------------------------------------------------------|
|                 |                             | Hot/Ordinal) serta aplikasi <i>scaling</i> (StandardScaler).                                                         |
| Inference       | Trained Random Forest Model | Model melakukan kalkulasi pada fitur input untuk menentukan skor probabilitas pada tiap tingkatan <i>burnout</i> .   |
| Post-Processing | Output Formatter            | Decode label (0→Rendah, 1→Sedang, 2→Tinggi) dan penghitungan <i>confidence score</i> berdasarkan probabilitas kelas. |
| Output          | Response (UI/Dashboard)     | Visualisasi tingkat risiko, grafik kontribusi fitur (SHAP), dan cetak rekomendasi tindakan untuk manajemen SDM.      |

### 5.3 Format Input dan Output

#### Format Input (HTTP POST /predict):

```
{
  "work_hours_per_week": 55,
  "overtime_hours": 15,
  "remote_work_status": "WFO",
  "access_to_mental_health": "No",
  "stress_level": 8,
  "years_of_experience": 5,
  "sleep_quality": 2,
  "job_role": "Manager"
}
```

#### Format Output (JSON Response):

```
{
  "burnout_level": "Tinggi",
  "confidence": 0.7015,
  "probabilities": {
```

```

    "Rendah": 0.0820,
    "Sedang": 0.2165,
    "Tinggi": 0.7015
  },
  "processing_time_ms": 12
}

```

| Komponen      | Format Input                                  | Format Output                                                  |
|---------------|-----------------------------------------------|----------------------------------------------------------------|
| Data          | Form interaktif / JSON POST                   | JSON response + visualisasi                                    |
| Tipe          | Numerik + Dropdown kategorikal                | String label + float probabilitas                              |
| Contoh Input  | {work_hours: 55, overtime: 15, wfh: WFO, ...} | -                                                              |
| Contoh Output | -                                             | {label: Tinggi, prob: {Rendah:0.08, Sedang:0.22, Tinggi:0.70}} |


## 5.4 Struktur Sistem Sederhana

Diagram Alur Inference:

User Input (Streamlit Form) → Input Validation → Preprocessing Pipeline (encoder + scaler dari joblib) → Model Inference (best\_model.pkl) → Predict Proba → Post-processing (label decoding, SHAP) → Output Display (Risk Level + Probability Chart + Rekomendasi)

| Komponen         | File/Direktori            | Fungsi                                                                                              |
|------------------|---------------------------|-----------------------------------------------------------------------------------------------------|
| Model File       | model/best_rf_model.pkl   | <i>Weights</i> dan parameter model Random Forest hasil <i>training</i> .                            |
| Pipeline File    | model/preprocessor.joblib | Objek <i>pipeline</i> yang menyimpan <i>encoder</i> dan <i>scaler</i> untuk data.                   |
| Script Inference | inference.py              | Fungsi <i>load_all()</i> , <i>preprocess()</i> , <i>predict()</i> , dan <i>interpret_shap()</i> .   |
| API Server       | app/main.py               | Aplikasi FastAPI dengan <i>endpoint</i> POST <i>/predict</i> untuk integrasi sistem.                |
| Pydantic Schema  | app/schemas.py            | Definisi struktur <i>BurnoutRequest</i> dan <i>BurnoutResponse</i> .                                |
| Streamlit UI     | streamlit_app.py          | Antarmuka visual: <i>input form</i> , tampilan level risiko, dan chart probabilitas.                |
| Requirements     | requirements.txt          | Daftar <i>library</i> : scikit-learn, pandas, fastapi, streamlit, shap, joblib.                     |
| Docker           | Dockerfile                | Konfigurasi <i>containerisasi</i> untuk memastikan sistem berjalan di berbagai <i>environment</i> . |

Struktur File Sistem:



| File / Folder                       | Fungsi                                                  |
|-------------------------------------|---------------------------------------------------------|
| burnout_app/app.py                  | Main Streamlit application (UI + inference logic)       |
| burnout_app/model/best_model.pkl    | Serialized model terbaik (RF atau SVM hasil tuning)     |
| burnout_app/model/preprocessor.pkl  | Pipeline preprocessing (encoder + scaler)               |
| burnout_app/model/label_encoder.pkl | Label encoder untuk target Burnout_Level                |
| burnout_app/utills/predict.py       | Script inference: load model, preprocess input, predict |
| burnout_app/utills/visualize.py     | Script visualisasi: SHAP, probability chart             |
| requirements.txt                    | Daftar dependensi Python                                |
| README.md                           | Dokumentasi cara menjalankan aplikasi                   |

## 5.5 Arsitektur Sederhana

Arsitektur yang digunakan adalah Single-Tier Local/Cloud App. Seluruh komponen (UI, preprocessing, model inference) berjalan dalam satu proses Streamlit. Model disimpan sebagai file .pkl dan dimuat ke memori saat startup. Untuk produksi, dapat ditingkatkan ke arsitektur dua tier dengan FastAPI sebagai backend terpisah dan Streamlit sebagai frontend.

| Layer                     | Komponen                                                  | Teknologi                             |
|---------------------------|-----------------------------------------------------------|---------------------------------------|
| Presentation Layer        | Web UI untuk demo interaktif                              | Streamlit (Python)                    |
| API Layer                 | REST API <i>endpoint</i> untuk <i>inference</i>           | FastAPI + Uvicorn                     |
| Processing Layer          | <i>Preprocessing</i> + <i>Encoding</i> + <i>Inference</i> | Python + Scikit-learn + Pandas        |
| Model Layer               | <i>Trained Random Forest weights</i> + <i>config</i>      | Scikit-learn (.pkl atau .joblib file) |
| Infrastructure (opsional) | Kontainerisasi dan <i>deployment cloud</i>                | Docker + Streamlit Cloud / Railway    |

## DAFTAR REFERENSI

- Maulia, A. H., & Salam, A. (2026). Benchmarking Oversampling Strategies to Enhance the Performance of Machine Learning Algorithms in Hypertension Classification. *Journal of Applied Informatics and Computing (JAIC)*, 10(1). (Acuan metodologi komparasi algoritma ML dan teknik evaluasi model klasifikasi).
- Salam, A., & Ma'ruf, F. A. (2025). Perbandingan Algoritma Machine Learning Dalam Memprediksi Kelulusan Siswa. *Jurnal Minfo Polgan*. (Referensi teknik preprocessing dan perbandingan algoritma pada data tabular).
- Kaggle. (2026). Employee Mental Health & Burnout Dataset. Diakses dari Kaggle Repository.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- Cortes, C., & Vapnik, V. (1995). Support-Vector Networks. *Machine Learning*, 20(3), 273–297.
- Chawla, N. V., et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321–357.